



Ayudantía 8

Árboles de decisión, *Ensamblés* y Presentación T4

Por Melanie Castillo y Rodrigo Figueroa

25 de Mayo 2025



Contenidos

- *Árboles de decisión.*
- *Ensamblés*
- *Presentación Tarea 4*



Árboles de decisión

- Técnica de aprendizaje supervisado
- Usados para clasificación y regresión.
- Organizan los datos para dividirlos en diferentes clases.



Árboles de decisión

Clima	Temperatura	Humedad	Viento	Jugar?
soleado	alta	alta	F	No
soleado	alta	alta	V	No
nublado	alta	alta	F	Si
lluvioso	Agradable	alta	F	Si
lluvioso	frio	normal	F	Si
lluvioso	frio	normal	V	No
nublado	frio	normal	V	Si
soleado	Agradable	alta	F	No
soleado	frio	normal	F	Si
lluvioso	Agradable	normal	F	Si
soleado	Agradable	normal	V	Si
nublado	Agradable	alta	V	Si
nublado	alta	normal	F	Si
lluvioso	Agradable	alta	V	No




Imagen obtenida de la clase de árboles de decisión del profesor Hans Löbel 2025-1



Árboles de decisión

Estructura del Árbol:

- Raíz: Representa la totalidad de los datos.
- Nodos:
 - Cada nodo (excepto las hojas) es una pregunta o condición sobre alguna característica.
 - Según la respuesta, los datos se dividen en nodos del siguiente nivel.



Árboles de decisión

Estructura del Árbol:

- Para decidir la mejor división en un nodo se utilizan métricas como Gini, Entropía o índice de impureza.
- Elegimos la característica que entrega la mayor ganancia de información (mayor reducción de entropía)
- Estas son calculadas por los modelos automáticamente



Árboles de decisión

DecisionTreeClassifier

```
class sklearn.tree.DecisionTreeClassifier(*, criterion='gini', splitter='best',
max_depth=None, min_samples_split=2, min_samples_leaf=1,
min_weight_fraction_leaf=0.0, max_features=None, random_state=None,
max_leaf_nodes=None, min_impurity_decrease=0.0, class_weight=None, ccp_alpha=0.0,
monotonic_cst=None) \[source\]
```

A decision tree classifier.

Read more in the [User Guide](#).

Parameters:


criterion : {"gini", "entropy", "log_loss"}, default="gini"

The function to measure the quality of a split. Supported criteria are "gini" for the Gini impurity and "log_loss" and "entropy" both for the Shannon information gain, see [Mathematical formulation](#).

Fuente: DecisionTreeClassifier. (n.d.). Scikit-learn <https://scikit-learn.org/stable/modules/generated/sklearn.tree.DecisionTreeClassifier.html>



Sobreajuste es un problema importante para los árboles de decisión



Profundidad del árbol
en este caso

Imagen obtenida de la clase de árboles de decisión del profesor Hans Löbel 2025-1




Técnicas para reducir el sobreajuste

- Usar un conjunto de validación para detener el crecimiento.
- Detener cuando los datos restantes no son estadísticamente relevantes.
- Podar el árbol después de construirlo completamente.
- Penalizar la complejidad al seleccionar atributos.

Ejemplo de sobreajuste en árboles de decisión




¿Estudia más de 5 horas/semana?



Este árbol es poco profundo, tiene reglas generales. Puede que no sea perfecto, pero generaliza bien a nuevos estudiantes.

¿Estudia más de 5 horas/semana?



Este árbol tiene muchas divisiones específicas, como fechas y detalles muy concretos. Esto significa que está "aprendiendo de memoria" los datos del pasado, en vez de aprender patrones generales.



Más modelos


- El **árbol de decisión** tiene una gran ventaja: es simple y fácil de interpretar...
- ... pero puede sufrir serios problemas de sobreajuste



Más modelos

¿De dónde proviene el sobreajuste en un árbol de decisión?


- Al crear nuevos nodos en el entrenamiento (“bajar” en el árbol), la **muestra** se hace cada vez más reducida
- Si hay muchos **atributos**, es altamente probable elegir alguno bueno en los datos de entrenamiento, pero que es “inútil” para generalizar





Ensamblas de modelos con baja correlación


- Si el **patrón de error** (acierto) es **distinto** para todos, es altamente probable que, en promedio, la respuesta del ensamble sea correcta (los **errores se cancelan**)





Muestras aleatorias


- Tomemos varios **árboles de decisión** y armemos una gran **"votación"**, donde cada árbol tenga "un voto".
- Como vimos en la diapositiva pasada, necesitamos que los modelos tengan **baja correlación** para que nuestro plan resulte. **¿Cómo logramos esto?**
- Si cada modelo ve sólo una parte de los datos (elegida aleatoriamente), es probable que la **correlación** entre ellos **disminuya**






Atributos aleatorios

- Lo anterior no basta: **¿qué pasa si tenemos un atributo muy bueno?**
- La solución es similar: tomamos muestras aleatorias de atributos
- Esto no solo **disminuye la correlación**, sino que también **limita la profundidad del árbol**, reduciendo la complejidad de este



a) Low randomness, high tree correlation



b) High randomness, low tree correlation




Random Forest



Random Forest

- La introducción de todas estas estrategias basadas en **aleatoriedad**, aplicada a **varios árboles de decisión**, convierten esta técnica en un ensemble llamado **Random Forest**






Random Forest

- Un árbol para cada muestra aleatoria (subconjunto) de los datos.
- Árboles de **poca profundidad** para evitar el *overfitting*.
- La predicción final se obtiene de un promedio entre las predicciones de los árboles del bosque



Random Forest





Hiperparámetros: RF

- Los mismos de un árbol
- **n_estimators**: número de árboles en el bosque



Ventajas de *Random Forest*

- Al igual que los **árboles de decisión**, son **fácilmente interpretables**
- Rendimiento es **altamente competitivo** con datos **tabulados**
- Gracias a la aleatorización en su construcción, son altamente **resistentes al *overfitting***



Ventajas de *Random Forest*

- Todas estas ventajas hacen que ***Random Forest*** sea un modelo **altamente utilizado**, a día de hoy, en el mundo de *machine learning*



Ensembles




¿Qué son los ensambles?

- Combinación de múltiples modelos con el fin de **crear uno mejor.**



Tipos de ensambles : *Bagging*


- Crear **múltiples datasets** con muestreo **con reemplazo** y entrenar distintos modelos.
- Luego por alguna **decisión conjunta**, por ejemplo mayoría de votación se clasifica/predice.
- Random Forest es el clásico de estos modelos





Tipos de ensambles : *Stacking*


- Entrenar varios modelos con el mismo dataset. Se recomienda que sean ***weak learners***.
- Luego ***stackear*** (concatenar) los *outputs* de los modelos y usarlos como *inputs* para entrenar un ***metalearner***.
- Finalmente este *metalearner* genera el *ouput* esperado.






Tipos de ensambles : *Boosting*

- Aprovechar la **información errónea** de una jerarquía de modelos.
- De forma secuencial se entrenan modelos cada vez más débiles, para que estos **aprendan de los errores de los anteriores**.
- Luego se **combinan** para generar el output.





Gradient Boosting





Algorithm 2 Gradient Boosting

Input Data: $x_i \in R^n, y_i \in [-1, +1]$

1: **Initialize** $F_0(x) = \operatorname{argmin}_{\gamma} \sum_{i=1}^n L(y_i, \gamma)$

2: **for** $m = 1$ to M **do**

3: Compute the negative gradient

$$r_{i,m} = - \left[\frac{\delta L(y_i, F(x_i))}{\delta F(x_i)} \right]$$

4: Fit tree to targets $r_{i,m}$, with leafs $R_{j,m}$

5: For $j = 1, 2, \dots, J_m$

$$\gamma_{jm} = \operatorname{argmin}_{\gamma} \sum_{x_i \in R_{ij}} L(y_i, F_{m-1}(x) + \gamma)$$

6: Update the estimation of $F(x)$

$$F_m(x) = F_{m-1}(x) + \nu(\gamma_{jm})$$

7: Output $\hat{f}(x) = f_M(x)$



Gradient Boosting : Clasificación

- Si los modelos son de **regresión** el error es simplemente la **diferencia** del valor predicho. ¿Pero qué pasa con los **problemas de clasificación**?
- No podemos usar la diferencia de clases como tal, puesto que no representan algo real*.
- Pero recordando los modelos de clasificación lo que hacen es calcular las **probabilidades de que pertenezcan a una clase**.



XGBoost : eXtreme Gradient Boosting

- Probablemente el algoritmo de boosting más utilizado.
- *Gradient Boosting* **no escala bien para muchos datos.**
- **XGboost:** Es una versión más eficiente, puesto que:
 - Agrega regularizadores L1 y L2 (quitan el overfitting)
 - Paraleliza las tareas
 - Tiene implementado una forma de **parar** con basado en Cross-Validation
 - Corta las zonas menos interesantes de árboles.



Ayudantía 8

Árboles de decisión, *Ensamblés* y Presentación T4

Por Melanie Castillo y Rodrigo Figueroa

25 de Mayo 2025